

MIMIR EVALUATION REPORT


DATA DI GENERAZIONE: 09/06/2026 - 21:33:50

DOCUMENT CONTROL & CONFIGURATION

Framework di Valutazione	DeepEval
File Dati Sorgente	risultati_test4_Agentic.csv
Stato del Testset	Esecuzione completata con 18 tracce analizzate
Metriche Valutate	Agentic Synthesis [GEval], Response Latency, Token Efficiency, Tool Hallucination

1. Global evaluation results analysis

Global Success Rate




Analisi dell'Affidabilit  Globale

Il grafico evidenzia il tasso di superamento dei test basato sulle soglie configurate nella libreria di valutazione. Attualmente, la compliance del sistema si attesta sul valore del 76.5% di risposte conformi ai requisiti di qualit . I casi non conformi (FAILED) indicano allucinazioni semantiche o risposte evasive che richiedono interventi di ottimizzazione della knowledge base.

SCORE MEDIO	LATENZA MEDIA DI VALUTAZIONE
0.77 / 1.00	58.80 s

2. Performance Metrics Analysis

Average Score per Metric




Interpretazione dell'Istogramma

L'istogramma scompone analiticamente le performance matematiche medie per ciascuna delle metriche configurate. Questo permette di isolare se le criticità prestazionali dell'agente risiedano nella fase di recupero delle informazioni dal database vettoriale o nella fase di generazione e sintesi linguistica.

3. Performance Heatmap

Performance Heatmap



Interpretazione della Mappa

La matrice traccia l'andamento di ogni singola domanda (asse Y) rispetto agli score ottenuti (asse X). I cluster con colorazione piu' chiara identificano cali di performance semantica che richiedono interventi correttivi prioritari.

4. Evaluation Log by Query

QUERY: Che licenza è stata assegnata per Hewett e qual è ... | Score Medio: 0.75

> Metrica: Agentic Synthesis [GEval] (Score: 1.00)

Output correctly cites the Hewett license (NSTA exploratory license) and the total CO2 storage capacity (500 million tonnes for HyNet North West and Bacton Thames Net Zero, including Hewett), and mentions Hewett startup by 2030 with initial 5 Mt/yr and expansion to 10 Mt/yr, all data drawn from the retrieval context.

> Metrica: Tool Hallucination (Score: 1.00)

Tool valido: l'agente ha usato 'hybrid_document_retriever_tool' che è tra quelli consentiti.

> Metrica: Response Latency (Score: 1.00)

Latenza: 3.77s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 89766 (Soglia massima impostata: 25000)

QUERY: Come che Eni punta a raggiungere la NEUTRALITÀ CAR... | Score Medio: 0.70

> Metrica: Agentic Synthesis [GEval] (Score: 0.80)

Allineamento forte: l'Output copre le tecnologie esistenti ed evolutive (gas ponte, biocarburanti/biometano, rinnovabili, CCUS, idrogeno low-carbon, breakthrough come fusione) e l'eccellenza operativa (integrità degli asset, sicurezza, disciplina finanziaria, diritti umani, resilienza, diversificazione) e mostra come gas + eccellenza supportino la transizione. Tuttavia introduce dettagli specifici non esplicitamente presenti nel testo (es. Baleine, sostituzione del gas russo, nomi/progetti o cifre) e l'enfasi su accessibilità/versatilità non è altrettanto esplicitamente collegata al contenuto dell'Input.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 5.695s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 33338 (Soglia massima impostata: 25000)

QUERY: Come ha inciso il calo della domanda, la pressione... | Score Medio: 0.75

> Metrica: Agentic Synthesis [GEval] (Score: 1.00)

Output allinea perfettamente con l'Input: elenca i tre fattori che hanno inciso nel 2023 (calo della domanda, pressione competitiva, elevati costi energetici europei), descrive l'impatto sui risultati e la necessità di ristrutturazione, riporta le iniziative tecnologiche: impianto Hoop® dimostrativo a Mantova con capacità 6.000 t/anno e avvio previsto fine 2024, collaborazione con Technip Energies, sviluppo di bioetanolo sostenibile da zuccheri di seconda generazione, integrazione di Novamont nel 2023 con sinergie, e sintesi sul passaggio a chimica bio-based e circolare. Non introduce dati non presenti.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 5.966s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 56702 (Soglia massima impostata: 25000)

QUERY: Congo: quali attività near-field sono citate e com... | Score Medio: 0.75**> Metrica: Agentic Synthesis [GEval] (Score: 1.00)**

Allineamento completo: l'Output si basa esclusivamente sui dati del Retrieval Context relativi a Congo LNG, includendo Tango FLNG, Excalibur FSU, capacità iniziale di 1 bcm, seconda unità da 3,5 bcm e plateau di circa 4,5 bcm, riferimenti al permesso Marine XII e alle due scoperte in Marine VI Bis, descrive come le attività near-field contribuiscano all'obiettivo del 60% di gas entro il 2030, con integrazione upstream-midstream e zero gas flaring, senza introdurre dati non supportati.

> Metrica: Tool Hallucination (Score: 1.00)

Tool valido: l'agente ha usato 'hybrid_document_retriever_tool' che è tra quelli consentiti.

> Metrica: Response Latency (Score: 1.00)

Latenza: 12.639s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 104876 (Soglia massima impostata: 25000)

QUERY: Da capo della strategia gas e M&A, come dovremmo c... | Score Medio: 0.97**> Metrica: Agentic Synthesis [GEval] (Score: 0.90)**

Allineamento molto forte: l'output richiama i due casi chiave (Baleine: primo progetto Africa a emissioni nette zero Scope 1 e 2, avviato in meno di due anni dalla scoperta, Congo Floating LNG: primo carico a fine febbraio 2024) e costruisce una narrazione strutturata attorno ai tre pilastri richiesti, centrando il gas e l'approccio pragmatico e sostenibile, coerentemente con l'input. L'unico difetto è l'aggiunta di elementi non esplicitamente presenti nel testo (es. linguaggio Energy Tech Company o riferimenti specifici a riduzioni di metano e flaring) che rappresentano estensioni non direttamente basate sui dati forniti.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 11.381s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 1.00)

Consumo Token: 11778 (Soglia massima impostata: 25000)

QUERY: Dove sono le proposte del Consiglio di Amministrazione? | Score Medio: 0.97**> Metrica: Agentic Synthesis [GEval] (Score: 0.90)**

La risposta risponde in modo sensato e coerente all'Input (indica una localizzazione specifica: pagina 462 della Relazione Finanziaria Annuale 2023). Poiché Retrieval Context è vuoto, non introduce dettagli fuori dal contesto e non contraddice alcun dato, l'output è chiaro, educato e pertinente alla domanda.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 1.108s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 1.00)

Consumo Token: 10741 (Soglia massima impostata: 25000)

QUERY: Dove sta la Relazione del Collegio Sindacale alla ... | Score Medio: 0.80**> Metrica: Agentic Synthesis [GEval] (Score: 0.20)**

L'Output fornisce una pagina specifica (pagina 532) della Relazione Finanziaria Annuale 2023, ma non c'è Retrieval Context e l'Input non identifica né il documento né la pagina, quindi l'informazione non è supportata e non è chiaro a quale documento si riferisca, creando disallineamento rispetto alla richiesta che chiede di localizzare la Relazione all'interno di 'sto documento.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 1.498s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 1.00)

Consumo Token: 10804 (Soglia massima impostata: 25000)

QUERY: ENI RFA 2023 Allegati bilancio: quali documenti so... | Score Medio: 0.70**> Metrica: Agentic Synthesis [GEval] (Score: 0.80)**

L'Output risponde all'Input descrivendo la sezione Allegati e i documenti contenuti (partecipazioni, variazioni, corrispettivi, dichiarazione non finanziaria, Relazioni della revisione, Relazione del Collegio Sindacale) come allegati ai bilanci consolidato ed esercizio. È coerente con l'Input e non introduce dati non presenti nel Retrieval Context. Può essere leggermente più sintetico nel presentare solo i documenti elencati.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 3.18s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 39837 (Soglia massima impostata: 25000)

QUERY: In che modo l'acquisizione di Neptune Energy ha ra... | Score Medio: 0.72**> Metrica: Agentic Synthesis [GEval] (Score: 0.90)**

L'Output si basa sui dati del Retrieval Context: menziona Neptune Energy finalizzata a gennaio 2024, contribuzione produzione >100k boe/g, ~4 bcm/anno per l'Europa, presenza geograficamente in Regno Unito, Algeria, Indonesia e Australia, includendo la quota Eni in Vår Energi, obiettivo crescita quota gas al 60% entro il 2030, focus su CCUS e decarbonizzazione. Nota di miglioramento: omette alcuni dettagli presenti nel contesto (ad es. l'acquisizione del business bp in Algeria e riferimenti all'acquisizione di asset Chevron in Indonesia), che riducono la completezza della sintesi.

> Metrica: Tool Hallucination (Score: 1.00)

Tool valido: l'agente ha usato 'hybrid_document_retriever_tool' che è tra quelli consentiti.

> Metrica: Response Latency (Score: 1.00)

Latenza: 4.505s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 32528 (Soglia massima impostata: 25000)

QUERY: La Relazione sulla gesitone include la Dichiarazio... | Score Medio: 0.82**> Metrica: Agentic Synthesis [GEval] (Score: 0.30)**

L'Output risponde sì, ma aggiunge dettagli non presenti nel contesto (pagina 152, riferimenti a GRI/TCFD/WEF). Con retrieval_context vuoto, avrebbe dovuto limitarsi a confermare l'inclusione della DNF per DL 254/2016 senza dati non forniti dall'Input.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 1.789s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 1.00)

Consumo Token: 10690 (Soglia massima impostata: 25000)

QUERY: Nel 2023 Eni iniziative decarbonizzazione e proget... | Score Medio: 0.72**> Metrica: Agentic Synthesis [GEval] (Score: 0.90)**

L'Output è pienamente in linea con la richiesta: discute l'impatto di Baleine e Congo FLNG sui risultati finanziari e sul TSR, coerentemente con l'Input e senza introdurre contenuti irrilevanti. È chiaro, educato e strutturato. Tuttavia, contiene numeri specifici (es. produzione, utile operativo pro forma, TSR) che non sono presenti nel prompt né nel Retrieval Context vuoto, quindi dipende da dati esterni non verificabili nel contesto fornito.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 3.994s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 32112 (Soglia massima impostata: 25000)

QUERY: Quali accordi e partecipazioni coinvolgono Energy ... | Score Medio: 0.75**> Metrica: Agentic Synthesis [GEval] (Score: 1.00)**

L'Output riflette fedelmente il contenuto del Retrieval Context: descrive l'accordo Plenitude-EIP (marzo 2024, 7,6%, aumento di capitale di 0,6 mld, EV di circa 10 mld) e riepiloga i progetti di espansione e acquisizioni (GreenIT-CIP, Vårgrønn-Energia Group, BlueFloat in Spagna, Helios UK PV, accordi Galileo, EDPR US, KazMunayGas, storage) con obiettivi di capacità (4 GW nel 2024, 8 GW nel 2027, oltre 15 GW entro 2030) e EBITDA attesi. Non introduce dati non supportati dal contesto Retrieval.

> Metrica: Tool Hallucination (Score: 1.00)

Tool valido: l'agente ha usato 'hybrid_document_retriever_tool' che è tra quelli consentiti.

> Metrica: Response Latency (Score: 1.00)

Latenza: 6.185s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 71670 (Soglia massima impostata: 25000)

QUERY: Quali componenti elenca l'ENI RFA 2023? | Score Medio: 1.00**> Metrica: Agentic Synthesis [GEval] (Score: 1.00)**

L'Output elenca correttamente i componenti principali dell'ENI RFA 2023 (Relazione sulla Gestione, Dichiarazione Consolidata di Carattere Non Finanziario, Bilancio Consolidato, Bilancio di Esercizio, Allegati) e include anche il Glossario, coerente con la domanda. In assenza di Retrieval Context, non introduce dati non presenti e resta sensato ed educato.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 4.115s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 1.00)

Consumo Token: 21379 (Soglia massima impostata: 25000)

QUERY: Quali iniziative negli Stati Uniti ha avviato Eni ... | Score Medio: 0.65**> Metrica: Agentic Synthesis [GEval] (Score: 0.60)**

La risposta descrive le iniziative statunitensi chiave (joint venture SBR con PBF per Chalmette, espansione fotovoltaica tramite Plenitude/EDPR e capacità ~0,48 GW, dati di flussi di cassa e investimenti) ed evidenzia la disciplina finanziaria. Tuttavia non riporta esplicitamente l'avvio della produzione del progetto Golden Buckle in Texas come richiesto, sostituendolo con l'acquisizione di tre impianti in Texas/Ohio (Cattlemen, Timber Road, Blue Harvest), quindi manca una corrispondenza puntuale con i dettagli del test case.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 4.528s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 40714 (Soglia massima impostata: 25000)

QUERY: Quali iniziative strategiche sono allo studio tra ... | Score Medio: 0.57**> Metrica: Agentic Synthesis [GEval] (Score: 0.30)**

La risposta cita una joint venture con LG Chem in Corea del Sud invece che nel Sud-est asiatico richiesto, creando incongruenza con l'Input. Inoltre introduce dettagli numerici non presenti nell'Input (400.000 ton/anno, 2026, Ecofining) e usa una formulazione che implica una firma anziché iniziative ancora in studio, non essendoci Retrieval Context, non è possibile basarsi su dati verificabili dall'input.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 8.855s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 31397 (Soglia massima impostata: 25000)

QUERY: Quali risultati del settore GGP descritti nel cont... | Score Medio: 0.75**> Metrica: Agentic Synthesis [GEval] (Score: 1.00)**

La risposta è pienamente allineata con i dati del Retrieval Context: cita i numeri chiave presenti (10,1 milioni di clienti Plenitude, 3 GW di capacità rinnovabile e 19 mila punti di ricarica), l'obiettivo di portare la quota gasUpstream al 60% entro il 2030, i contratti GNL a lungo termine Congo/Indonesia/Qatar per circa 6,8 bcm/anno, l'accordo MoU con SPP, l'ingresso di EIP in Plenitude (7,6% e 0,6 mld ?), emissioni Scope 1 pari a 0,69 Mt CO2e, vendite gas 50,51 bcm e GNL 9,6 bcm, oltre al dato di zero infortuni. Non introduce dati non presenti e coglie le principali sinergie tra GGP e Plenitude.

> Metrica: Tool Hallucination (Score: 1.00)

Tool valido: l'agente ha usato 'hybrid_document_retriever_tool' che è tra quelli consentiti.

> Metrica: Response Latency (Score: 1.00)

Latenza: 5.146s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 52177 (Soglia massima impostata: 25000)

QUERY: Versalis, perché ha preso colpo nel 2023 e come il... | Score Medio: 0.70**> Metrica: Agentic Synthesis [GEval] (Score: 0.80)**

Strengths: l'Output risponde direttamente alle domande del test case, spiegando le ragioni del 2023 (calo domanda, costi energetici elevati, competitività) e riassumendo il piano 2024-2027 con l'obiettivo di pareggiare EBITDA nel 2025 e avere EBIT positivo nel 2026, oltre a indicare il riposizionamento verso chimica bio-based e circolarità e gli investimenti. È coerente con l'Input e rimane sensato e rispettoso del contesto senza inserirsi in dati non forniti dal retrieval context vuoto. Shortcoming: introduce dettagli (es. acquisizione di Novamont, Hoop) che non sono esplicitati nel test case e potrebbero andare oltre i dati presentati, riducendo la stretta aderenza ai contenuti forniti.

> Metrica: Tool Hallucination (Score: 1.00)

Nessun tool chiamato. Comportamento testuale standard.

> Metrica: Response Latency (Score: 1.00)

Latenza: 4.344s (Soglia: 15.0s)

> Metrica: Token Efficiency (Score: 0.00)

Consumo Token: 39090 (Soglia massima impostata: 25000)

Fine del Report di Valutazione