

MIMIR EVALUATION REPORT


DATA DI GENERAZIONE: 10/06/2026 - 12:17:26

DOCUMENT CONTROL & CONFIGURATION

Framework di Valutazione	DeepEval
File Dati Sorgente	risultati_testRAG1.csv
Stato del Testset	Esecuzione completata con 5 tracce analizzate
Metriche Valutate	AnswerRelevancy, ContextualRelevancy, Faithfulness

1. Global evaluation results analysis

Global Success Rate




Analisi dell'Affidabilit  Globale

Il grafico evidenzia il tasso di superamento dei test basato sulle soglie configurate nella libreria di valutazione. Attualmente, la compliance del sistema si attesta sul valore del 80.0% di risposte conformi ai requisiti di qualit . I casi non conformi (FAILED) indicano allucinazioni semantiche o risposte evasive che richiedono interventi di ottimizzazione della knowledge base.

SCORE MEDIO	LATENZA MEDIA DI VALUTAZIONE
0.76 / 1.00	330.66 s

2. Performance Metrics Analysis

Average Score per Metric




Interpretazione dell'Istogramma

L'istogramma scompone analiticamente le performance matematiche medie per ciascuna delle metriche configurate. Questo permette di isolare se le criticità prestazionali dell'agente risiedano nella fase di recupero delle informazioni dal database vettoriale o nella fase di generazione e sintesi linguistica.

3. Performance Heatmap

Performance Heatmap



Interpretazione della Mappa

La matrice traccia l'andamento di ogni singola domanda (asse Y) rispetto agli score ottenuti (asse X). I cluster con colorazione piu' chiara identificano cali di performance semantica che richiedono interventi correttivi prioritari.

4. Evaluation Log by Query

QUERY: Come analista di reporting finanziario di Eni, dov... | Score Medio: 0.84

> Metrica: Faithfulness (Score: 1.00)

No contradictions detected, the actual output fully aligns with the retrieval context. Great job!

> Metrica: AnswerRelevancy (Score: 1.00)

Il punteggio è 1.00 perché non ci sono elementi irrilevanti nell'output rispetto alla domanda, quindi non si può giustificare un punteggio più alto, tuttavia manca una risposta concreta che indichi la posizione della sezione 'Principali eventi dell'anno' e le altre voci principali del sommario con le relative pagine.

> Metrica: ContextualRelevancy (Score: 0.51)

The score is 0.51 because the retrieval context is largely irrelevant, e.g., "Irrelevant to the input: 'di distributori in oltre 40 Paesi in tutto il mondo, è leader mondiale nella produzione di bioplastiche e nello sviluppo di biochemical e bioprodotto attraverso l'integrazione di chimica, ambiente e agricoltura.'" and other unrelated items, and does not address the location of the 'Principali eventi dell'anno' section, however, it includes relevant cues such as "Principali eventi dell'anno ? pagina 12" and "Relazione sulla gestione ? pagina 5" indicating where the information can be found.

QUERY: Da capo della strategia gas e M&A, come dovremmo c... | Score Medio: 0.84

> Metrica: Faithfulness (Score: 1.00)

The score is 1.00 because there are no contradictions between the actual output and the retrieval context, indicating strong faithfulness, great job!

> Metrica: AnswerRelevancy (Score: 1.00)

Il punteggio è 1.00 perché non ci sono elementi irrilevanti nell'output: tutto è pertinente al tema richiesto (comunicare il contributo Africa con esempi Baleine e Congo FLNG e l'importanza dell'esecuzione). Poiché 1.00 è già il massimo, non potrebbe essere più alto. Ottimo focus e chiarezza?continua così.

> Metrica: ContextualRelevancy (Score: 0.52)

The score is 0.52 because the input centers on Africa's gas strategy and projects Baleine (Costa d'Avorio) and Congo LNG, which is supported by Africa-specific items like 'AFRICA ALGERIA ANGOLA CONGO COSTA D'AVORIO EGITTO GHANA KENYA LIBIA MAROCCO MOZAMBICO NIGERIA TUNISIA' and by energy-transition context such as 'TRANSIZIONE ENERGETICA E SOSTENIBILITÀ Sottoscritto con ADNOC un Memorandum of Understanding (MoU) che delinea un quadro di cooperazione per futuri progetti congiunti in ambito di transizione energetica, sostenibilità e decarbonizzazione.' However, the retrieval context also contains many clearly irrelevant items such as 'è leader mondiale nella produzione di bioplastiche e nello sviluppo di biochemical e bioprodotto' and 'IKEA, per l'installazione di 250 stazioni di ricarica di ultima generazione' that do not pertain to Africa or the energy-transition plan, diluting relevance. The presence of Africa-focused cues alongside numerous irrelevancies yields a moderate relevance score (0.52).

QUERY: Dove sono le proposte del Consiglio di Amministrazione? | Score Medio: 0.67

> Metrica: Faithfulness (Score: 1.00)

The score is 1.00 because there are no contradictions between the actual output and the retrieval context, everything aligns as expected. Great job!

> Metrica: AnswerRelevancy (Score: 1.00)

Il quesito chiede dove si trovano le proposte del CDA, l'output non risponde o non fornisce indicazioni utili, quindi la pertinenza è bassa (1.00). La lista di contenuti irrilevanti è vuota, quindi non ci sono elementi estranei da segnalare che potrebbero giustificare un punteggio più alto.

> Metrica: ContextualRelevancy (Score: 0.02)

The score is 0.02 because the input asks for the Board of Directors' proposals, but the retrieval context is largely unrelated. The only relevant line is: Proposte del Consiglio di Amministrazione all'Assemblea degli Azionisti. Irrelevancy notes also state: 'La dichiarazione descrive l'attività aziendale in termini generali e non menziona proposte del Consiglio di Amministrazione.' and many items refer to unrelated topics like 'Relazione della società di revisione sul bilancio consolidato' or a Disclaimer.

QUERY: Dove sta la Relazione del Collegio Sindacale alla ... | Score Medio: 0.68**> Metrica: Faithfulness (Score: 1.00)**

The score is 1.00 because there are no contradictions between the actual output and the retrieval context.

> Metrica: AnswerRelevancy (Score: 1.00)

Non ci sono elementi irrilevanti nell'output, quindi il punteggio non può aumentare per irrilevanza. Bene: è chiaro e privo di contenuti fuorvianti, ma la risposta non ha effettivamente localizzato dove si trova la Relazione del Collegio Sindacale nel documento, perciò il punteggio resta 1.00.

> Metrica: ContextualRelevancy (Score: 0.04)

The score is 0.04 because the retrieval context is largely unrelated to locating the Relazione del Collegio Sindacale: e.g., 'La presenza nel contesto è 'RELAZIONE SULLA GESTIONE', che è una 'relazione di gestione', non la 'Relazione del Collegio Sindacale' richiesta. The only items actually relevant are 'Relazione della società di revisione sul bilancio d'esercizio 524 Sindacale all'Assemblea degli azionisti' and 'Relazione del Collegio 532'.

QUERY: La Relazione sulla gestione include la Dichiarazio... | Score Medio: 0.76**> Metrica: Faithfulness (Score: 1.00)**

The score is 1.00 because there are no contradictions between the actual output and the retrieval context, indicating the output matches perfectly.

> Metrica: AnswerRelevancy (Score: 1.00)

The score is 1.00 because there were no irrelevant statements in the output, so the response remains fully relevant to the question about whether Eni SpA's Consolidated Non-Financial Statement complies with Legislative Decree 254/2016. Great job staying on topic!

> Metrica: ContextualRelevancy (Score: 0.29)

The score is 0.29 because the input asks whether the Relazione sulla gestione includes the DNF per DL 254/2016, and while the relevant lines include "La presente Relazione sulla gestione include la Dichiarazione consolidata di carattere Non Finanziario (DNF) in adempimento ai requisiti del Decreto Legislativo n. 254/2016 in materia di informazioni non finanziarie" and "DICHIARAZIONE CONSOLIDATA DI CARATTERE NON FINANZIARIO (DNF).", the retrieval context is dominated by irrelevancies such as "The statement discusses ESEF compliance rather than the inclusion of the Non-Financial Consolidated Statement per Legislative Decree 254/2016." and "La dichiarazione parla di acquisti di petrolio e volumi operativi, contenuti operativi/finanziari, non della Dichiarazione consolidata di carattere Non Finanziario prevista dal Decreto Legislativo n. 254/2016."

Fine del Report di Valutazione